第 55 卷 第 7 期
2022 年 7 月

中国电力
ELECTRIC POWER

Vol. 55, No. 7
Jul. 2022



基于特征选择和组合模型的短期电力负荷预测

徐宇颂[1,2]，邹山花[3]，卢先领[1,2]

(1. 江南大学 “轻工过程先进控制”教育部重点实验室，江苏 无锡 214122；2. 江南大学 物联网工程学院，江苏 无锡 214122；3. 江苏省物联网应用技术重点建设实验室，江苏 无锡 214100)

摘 要：提出基于特征选择和组合模型的短期电力负荷预测方法。首先将特征向量按特点分为 2 类，分别使用斯皮尔曼相关系数、最大相关最小冗余算法进行选择，依据贝叶斯信息量准则确定最优特征向量维度。然后使用 3 个不同的核函数建立单核递归支持向量回归模型并完成预测。最后构建神经网络，进行实验分析。仿真结果表明所提方法具有较高的预测精度与鲁棒性。

关键词：短期负荷预测；支持向量回归；浅层神经网络；组合模型

DOI：10.11930/j.issn.1004-9649.202111045

0 引言

负荷预测为电网安全稳定运行提供了可靠的依据[1]。目前负荷预测方法主要划分为统计学预测[2-5]和机器学习预测[6-13]。统计学预测方法如自回归移动平均模型[2-3]、时间序列分析[4-5]等，方法简单、预测速度快，但难以根据非线性因素构建理想数学模型。在机器学习预测方法中，人工神经网络（artificial neural network，ANN）具有较好的非线性拟合能力，但容易陷入局部最优[6-8]。长短期记忆神经网络（long short-term memory，LSTM）能较好把握时间相关性的数据，但对于输入数据要求较高[9-11]。支持向量回归（support vector regression，SVR）具有性能优良、唯一全局最优解、特征输入不挑剔等优点[12-13]。文献 [12] 分别采用反向传播神经网络、径向基功能神经网络、广义回归神经网络（general regression neural network，GRNN）和 SVR 预测某居民住宅区年电力负荷。SVR 模型存在“核函数选择”的问题[14-15]。文献 [16] 提出“多核组合模型”思路，并验证了最优组合模型预测效果优于单核模型，但仅将单核模型依据误差的倒数进行线性组合，效果未达到全局最优。

短期电力负荷预测方法一般会忽视特征选择的重要性，其往往根据经验选择特征或者使用单一标准进行特征选择，这将造成如下问题。（1）各地用电情况差异性大，受经验局限，缺乏可量化比较的选择标准，易遗漏重要特征；（2）单一标准未必适配所有类型的特征选择，获取的“高相关”特征不仅可信度存疑，还存在特征间“高冗余”问题；（3）常用方法不能有效确定模型维度，导致模型复杂度偏高或偏低，影响后续预测工作。

本文提出基于特征选择和组合模型的短期电力负荷预测方法，对未来 24 小时电力负荷进行预测。首先使用分类选择和贝叶斯信息量准则（Bayesian information criterion，BIC）确定最优特征向量及其维度。然后采用不同核函数建立单核递归支持向量回归模型（recursive support vector regression，RSVR），进行递归预测。接着运用各单核模型的训练输出构建浅层神经网络进行模型组合。最后结合实际案例进行验证，说明了本文方法具有较高的预测精度与鲁棒性。

1 分类特征选择方法

本文将特征向量分为外部因素特征向量与延迟负荷特征向量，使用斯皮尔曼相关系数（Spearman's rank-order correlation coefficient，

收稿日期：2021-11-10；**修回日期：**2022-05-16。

基金项目：国家自然科学基金资助项目（61573167）；教育部科技发展中心“云数融合科教创新”基金资助项目（2017A13055）。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

SROCC）与最大相关最小冗余算法（max-relevance and min-redundancy，mRMR）进行类内选择，解决选择标准单一问题。采用贝叶斯信息量准则确定最优特征向量的维度，在保证预测精确度的前提下降低模型的复杂度。

1.1 斯皮尔曼相关系数

斯皮尔曼相关系数是非参数指标，计算采用的数据是“秩”。当某外部因素是影响电力负荷变化的主要特征时，值接近于 1，反之接近于 0。本文选择大于等于 0.4 的相关特征向量以构造外部因素特征向量 $\boldsymbol{E}$。斯皮尔曼相关系数表达式为

$$\rho=\left|\frac{\sum_{i=1}^{n}\left(R_i-\bar{R}\right)\left(S_i-\bar{S}\right)}{\sqrt{\sum_{i=1}^{n}\left(R_i-\bar{R}\right)^2\sum_{i=1}^{n}\left(S_i-\bar{S}\right)^2}}\right| \tag{1}$$

式中：ρ为 2 组向量间的斯皮尔曼相关系数；n 为样本个数；R_i、S_i分别为 2 组向量的第 i 个参数；$\bar{R}$、$\bar{S}$分别为 2 组向量的平均等级。

相关系数大小与相关程度对应关系如表 1 所示。

表 1 系数的对应关系

Table 1 Corresponding relationship of coefficient

ρ/%	相关程度
0~19	极低相关
20~39	低度相关
40~69	中度相关
70~89	高度相关
90~100	极高相关

1.2 mRMR 算法

考虑到预测日内所有时刻负荷数据均未知，且电力负荷存在一定周期性。设初始延迟负荷特征向量为 $\boldsymbol{L}$，t 时刻前 d 小时的负荷向量为 $\boldsymbol{y}_{t-d}$。延迟负荷特征向量与负荷向量的关系是非线性。特征向量间存在严重的冗余现象。在进行类内选择时，不仅要选取“高相关”，也要做到“低冗余”，mRMR 算法最为合适。mRMR 算法是利用互信息技术保证特征向量高相关、低冗余的重要工具[17]。互信息运算表达式为

$$I(\boldsymbol{l},\boldsymbol{y})=\iint p(\boldsymbol{l},\boldsymbol{y})\log\frac{p(\boldsymbol{l},\boldsymbol{y})}{p(\boldsymbol{l})p(\boldsymbol{y})}\mathrm{d}\boldsymbol{l}\mathrm{d}\boldsymbol{y} \tag{2}$$

式中：$I(\boldsymbol{l},\boldsymbol{y})$为延迟负荷特征向量 $\boldsymbol{l}$ 和负荷向量 $\boldsymbol{y}$ 的互信息值；$p(\boldsymbol{l},\boldsymbol{y})$为向量 $\boldsymbol{l}$ 和向量 $\boldsymbol{y}$ 的联合概率分布函数；$p(\boldsymbol{l})$、$p(\boldsymbol{y})$分别为向量 $\boldsymbol{l}$ 和向量 $\boldsymbol{y}$ 的概率分布。

算法步骤如下。（1）将 $\boldsymbol{L}$ 中的向量 $\boldsymbol{l}$ 与 $\boldsymbol{y}$ 进行互信息运算；（2）选择取值最大者存入候选延迟负荷特征向量 $\boldsymbol{J}$ 作为首项；（3）在剩余向量中进行综合运算，将值最大者存入 $\boldsymbol{J}$；（4）重复上述步骤直至 $\boldsymbol{J}$ 的维度达到设定值 Q，输出 $\boldsymbol{J}$。

综合运算表达式为

$$\max\left[I\left(\boldsymbol{l}_j,\boldsymbol{y}\right)-\frac{1}{q-1}\sum I\left(\boldsymbol{l}_j,\boldsymbol{l}_i\right)\right] \tag{3}$$

式中：$\boldsymbol{l}_i$为第 i 个已存入 $\boldsymbol{J}$ 的延迟负荷向量；$\boldsymbol{l}_j$为第 j 个还未存入 $\boldsymbol{J}$ 的向量；q 为 $\boldsymbol{J}$ 的维度；$I\left(\boldsymbol{l}_j,\boldsymbol{y}\right)$为延迟负荷特征向量与负荷向量的相关度；$I\left(\boldsymbol{l}_j,\boldsymbol{l}_i\right)$为延迟负荷特征向量间的冗余度。

1.3 贝叶斯信息量准则

分类选择后，获取综合特征向量 $\boldsymbol{F}=\{\boldsymbol{E},\boldsymbol{J}\}$。训练模型时，如果模型维度过大，会导致过拟合、计算资源浪费等问题，反之容易欠拟合。BIC 是确定模型维度的有效方法，能规避过拟合的风险[18]。BIC 运算表达式为

$$V_{\mathrm{BIC}}=m\ln(n)+n\ln\left(\sum_{i=1}^{n_{\mathrm{v}}}(y_i-\hat{y}_i)/n\right) \tag{4}$$

式中：V_{BIC}为模型的 BIC 值；m 为特征维度；n_{v}为验证集样本个数；y_i为负荷向量验证集中第 i 个实际值；$\hat{y}_i$为第 i 个预测值。

2 组合模型

2.1 支持向量回归与递归预测

SVR 具有良好的泛化性能和严密的统计学理论基础[19-20]，其基本思想是：给定训练样本，寻求相应的非线性映射，将输入向量投射到更高维的特征空间中进行线性函数拟合。其运算表达式为

$$f(\boldsymbol{x})=\boldsymbol{\omega}^{\mathrm{T}}\varphi(\boldsymbol{x})+b \tag{5}$$

式中：$f(\boldsymbol{x})$为模型输出结果；$\boldsymbol{\omega}$ 为权值向量；$\varphi(\boldsymbol{x})$为高维映射函数；$\boldsymbol{x}$ 为输入特征向量；b 为阈值变量。

SVR 引入“结构风险”的概念，并使用惩罚

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net



因子将其与“经验风险”进行折中平衡，以求总体风险最小化。为进一步规避“过拟合”风险，加入松弛变量创建“软间隔”，以提升泛化性能。其表达式为

$$\min\left[\frac{1}{2}\boldsymbol{\omega}^{\mathrm{T}}\boldsymbol{\omega}+C\sum_{i=1}^{n}\left(\xi_i+\xi_i^*\right)\right]$$
$$\text{st.}\begin{cases}-y_i+f(\boldsymbol{x}_i)\leqslant\varepsilon+\xi_i\\ -f(\boldsymbol{x}_i)+y_i\leqslant\varepsilon+\xi_i^*\\ \xi_i,\xi_i^*\geqslant 0,\ i=1,2,\cdots,n\end{cases}\tag{6}$$

式中：C为惩罚因子，用于平衡经验风险与结构风险；n为样本个数；ξ_i、ξ_i^*分别为松弛变量；y_i为第i个真实值；$\boldsymbol{x}_i$为第i个输入向量；$f(\boldsymbol{x}_i)$为第i个预测值；ε为不敏感损失系数。

随后引入拉格朗日因子，利用 Karush-Kuhn-Tucker 条件将原问题转换为对偶问题进行优化求解，即

$$f(\boldsymbol{x})=\sum_{i=1}^{n}\left(\alpha_i-\alpha_i^*\right)\varphi(\boldsymbol{x}_i)^{\mathrm{T}}\varphi(\boldsymbol{x})+\boldsymbol{b}\tag{7}$$

式中：α_i、α_i^*分别为引入的拉格朗日乘子；$\boldsymbol{x}_i$为第i个输入向量；$\varphi(\boldsymbol{x})$为输入向量的映射输出向量；$\boldsymbol{b}$为阈值向量。

创建向量$\tilde{\boldsymbol{x}}_t=\{\boldsymbol{y}_{t-1},\boldsymbol{y}_{t-2},\ldots,\boldsymbol{y}_{t-\beta}\}$，$\boldsymbol{y}_{t-\beta}$为$t$时刻前$\beta$小时的负荷向量，本文设置$\beta$=1。在训练阶段，所有$\tilde{\boldsymbol{x}}_t$和$\boldsymbol{y}$都已知，可直接用于模型训练。

2.2　模型组合与浅层神经网络

电力负荷是非线性复杂时间序列，即使各单核模型预测性能都优良，在模型组合时也会存在精度提升不显著的可能。浅层神经网络的自学习能力可以自行优化组合结构，从而提升预测准确度。同时神经网络的容错性将提升总体模型的鲁棒性[21]。

浅层神经网络一般由输入层、单隐义层、输出层构成，神经网络中不同层的值通过权值运算、激活函数传递给后面的层。神经网络运算表达式为

$$\begin{cases}\hat{\boldsymbol{y}}=\boldsymbol{a}_2=\sigma_2\boldsymbol{z}_2=\sigma_2(\boldsymbol{w}_2\boldsymbol{a}_1+\boldsymbol{b}_2)\\ \boldsymbol{a}_1=\sigma_1\boldsymbol{z}_1=\sigma_1(\boldsymbol{w}_1\boldsymbol{O}+\boldsymbol{b}_1)\\ \boldsymbol{O}=[\boldsymbol{o}_1,\boldsymbol{o}_2,\boldsymbol{o}_3]\end{cases}\tag{8}$$

式中：$\boldsymbol{a}_1$、$\boldsymbol{a}_2$与σ_1、σ_2分别为隐义层和输出层的输出向量和激活函数；$\boldsymbol{w}_1$、$\boldsymbol{w}_2$与$\boldsymbol{b}_1$、$\boldsymbol{b}_2$分别为隐义层和输出层的权值向量和阈值向量；$\boldsymbol{z}_1$、$\boldsymbol{z}_2$分别为通过对应激活函数后的输入层和隐义层的输出向量；$\boldsymbol{O}$为含有 3 个单核模型预测输出结果$\boldsymbol{o}_1$、$\boldsymbol{o}_2$、$\boldsymbol{o}_3$的输入向量。

在训练过程中，使用反向传播和 Levenberg-Marquardt 优化算法[22]对网络参数更新寻优。该优化算法是介于牛顿法与梯度下降法之间的 1 种非线性最小化方法，对于过参数化问题不敏感，能够有效处理冗余参数问题，使损失函数陷入局部极小值的机会大大减少[23]。损失函数使用的是均方误差（mean square error，MSE）。MSE 与平均绝对百分比误差（mean absolute percentage error，MAPE）作为估量各模型预测精度的评价标准。其运算表达式为

$$E_{\mathrm{MSE}}=\frac{1}{T}\sum_{t=1}^{T}(y_t-\hat{y}_t)^2\tag{9}$$

$$E_{\mathrm{MAPE}}=\frac{1}{T}\sum_{t=1}^{T}\frac{|y_t-\hat{y}_t|}{y_t}\times 100\%\tag{10}$$

式中：E_{MSE}、E_{MAPE}分别为模型的预测均方误差和平均绝对百分比误差；T为总时刻数；y_t为时刻t的电力负荷真实值；$\hat{y}_t$为t时刻的电力负荷预测值。

3　实例分析及仿真实验对比

3.1　分类特征选择

从气象网站上取马来西亚柔佛州某几日所有整点时刻的气象信息，包括紫外线指数、晴雨情况、风速等。利用斯皮尔曼相关系数剔除低相关的特征向量，得到外部因素特征向量$\boldsymbol{E}$。节假日数据以天为单位，与负荷向量数据粒度不统一，故取日平均负荷量进行相关性运算。外部因素特征向量$\boldsymbol{E}$如表 2 所示。

接着使用 mRMR 算法筛选初始延迟负荷特征向量$\boldsymbol{L}$，得到候选延迟负荷特征向量$\boldsymbol{J}$，初始维度Q设定为 50。将向量$\boldsymbol{E}$与向量$\boldsymbol{J}$相并得到综合特征向量$\boldsymbol{F}$。随后利用 3 折交叉验证法划分验证集并使用线性核 SVR 求得向量$\boldsymbol{F}$前m个维度的平均 BIC 值，如图 1 所示。

由图 1 可知，BIC 值在m=33 时达到最小，之后有所上升，而 MAPE 值在m=23 后平稳下降，其无法得出最佳模型维度。综上，BIC 比 MAPE 更适合作为模型维度选择准则。

以最小 BIC 值确定最优特征向量$\boldsymbol{F}_m$及其维度

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

表 2 特征向量 E
Table 2 Feature vector E

描述名称	显著性	ρ/%
紫外指数	显著	70.80
温度	显著	59.27
湿度	显著	58.11
风速	显著	56.92
云量	显著	8.81
露点	不显著	0.59
整点时刻	显著	76.41
日类型	显著	56.29
休假	显著	76.63

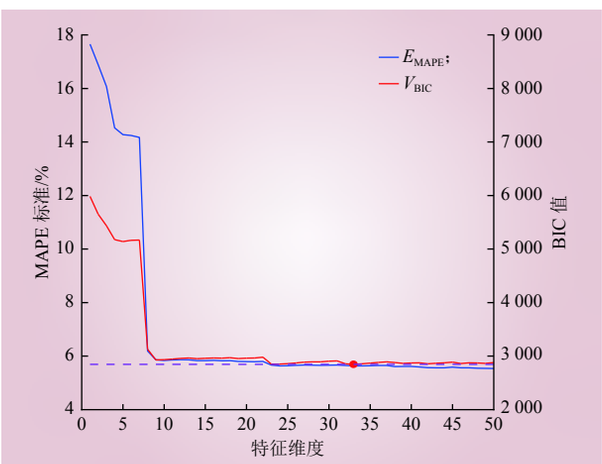


图 1 最优特征向量 F_m 维度与 BIC、MAPE 关系
Fig. 1 Relationship between the dimension of the optimal feature vector F_m and BIC, MAPE

m=33。$\boldsymbol{F}_m$ 中外部因素特征分别为紫外线、温度、湿度、风速、整点时刻、日类型、休假信息。延迟负荷特征分别为待预测日前 168、25、128、144、48、167、72、110、120、26、82、166、96、47、145、159、143、33、73、134、49、165、71、97、153、27 个小时的负荷特征向量。

以往特征选择方法分为 2 类：经验特征选择和单一标准特征选择。在本次对比实验中，前者直接选择温湿度、前 3 日的延迟负荷、前 1 周的延迟负荷作为输入特征向量。后者选择最大互信息系数（maximal information coefficient，MIC）作为选择标准。MIC 常用于衡量 2 个随机变量之间的非线性关系，不限定于特定的函数类型，符合普适性和公正性的要求[24]。使用 3 折交叉验证法分别求出 3 类特征选择方法的模型 BIC 值和 MAPE 值，数据如表 3 所示。

表 3 各特征选择方法的验证集误差
Table 3 The errors of validation set by different feature selection methods

特征选择方法	V_{BIC}	E_{MAPE}/%
分类特征选择	2 846.93	5.634 4
MIC特征选择	3 009.42	5.817 4
经验特征选择	3 056.93	5.842 0

从表 3 中可以看出，本文所提出的分类特征选择方法的性能优于其他方法。相比于 MIC 单一标准特征选择，它较好解决了特征向量间冗余、模型维度难以确定等问题。相对于经验特征选择，它不会遗漏重要属性特征。例如风速作为重要天气因素，能够改变体感温度从而间接影响用户用电行为[25]。

3.2 单核 RSVR 模型建立

通过分类特征选择方法获取最优特征向量 $\boldsymbol{F}_m$ 后，本文使用不同的核函数训练单核 RSVR 模型并进行递归预测，预测结果如表 4 所示。

表 4 单核RSVR的预测误差
Table 4 The forecasting errors of RSVR models based on different single-kernel

单核模型	训练集 E_{MSE}/GW	测试集 E_{MSE}/GW	测试集 E_{MAPE}/%
线性核RSVR	2.630 8	1.041 2	1.488 3
高斯核RSVR	1.767 2	0.474 6	1.077 1
S型核RSVR	4.414 6	1.594 3	2.098 5
高斯核SVR	6.353 5	1.553 5	2.481 9
高斯核SVRMIC特征选择	7.235 3	2.605 4	3.347 8
高斯核SVR经验特征选择	9.331 7	5.940 1	5.211 0

从表 4 中可以看出，在 3 个不同的单核模型中，高斯核 RSVR 模型的预测性能最优，线性核函数次之，S 型核函数最差。以高斯核模型为例，不采用递归预测时，测试集 MSE 为 1.553 5 GW，MAPE 为 2.481 9%。采用递归预测后，MSE 降为 0.474 6 GW，MAPE 降为 1.077 1%，可知引入前一时刻电力负荷数据然后进行递归预测的方法可以提升预测精度。此外，使用 MIC 特征选择方法或经验特征选择方法的高斯核模型的预测性能较

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net



差。结合表 3~4 可以看出，使用分类特征选择方法可以有效降低模型预测误差。

3.3　模型组合与对比实验

本文构建浅层神经网络对模型进行组合，记为 3 核递归支持向量回归-神经网络（recursive-support vector regression-neural network，RSVR-NN）组合模型。该神经网络依据单核模型的训练输出建立网络结构，然后将单核模型的预测输出作为自己的预测输入，神经网络的输出值为最终预测值。

本文在保证同一最优特征向量 $\boldsymbol{F}_m$ 的前提下，选择多个主流模型进行对比实验，预测性能对比情况如表 5 所示。

表 5　对比实验

Table 5　Comparative experiments

模型组合方案对比	测试集E_{MSE}/GW	测试集E_{MAPE}/%
3核RSVR线性组合	0.452 5	1.033 1
3核RSVR-NN组合	0.227 6	0.774 1
随机森林	1.708 2	2.177 4
LSTM	1.380 9	1.627 7
GRNN	1.233 1	1.840 6

本文按照文献 [16] 对它提出的方案模型进行还原。单核 RSVR 模型预测输出根据一定比例进行线性组合，对应比例为各模型训练集均方误差的倒数，记为 3 核 RSVR 线性组合模型，预测结果测试集 MSE 为 0.452 5 GW，MAPE 为 1.003 1%。

从表 4~5 中可以看出，单核 RSVR 最优模型预测结果测试集 MSE 为 0.474 6 GW，MAPE 为 1.077 1%，线性组合模型相比于单核模型性能有所提升，但是提升幅度不大，主要原因是模型根据误差倒数法线性组合的组合方式不一定最优。而神经网络具有优秀的自学习能力并且具有一定的容错性，组合方式更优，所以 3 核 RSVR-NN 组合模型能够取得较优的预测性能与鲁棒性，其测试集 MSE 为 0.227 6 GW，测试集 MAPE 为 0.774 1%。绘制 2 个组合模型的负荷预测曲线，如图 2 所示。

从图 2 可以看出，2 种组合方式都能对电力负荷进行较好的预测，3 核 RSVR-NN 组合模型更胜一筹。尤其是在 09:00—12:00 及 14:00—16:00，它比 3 核 RSVR 线性组合模型更贴合负荷实际曲线，预测效果更好。

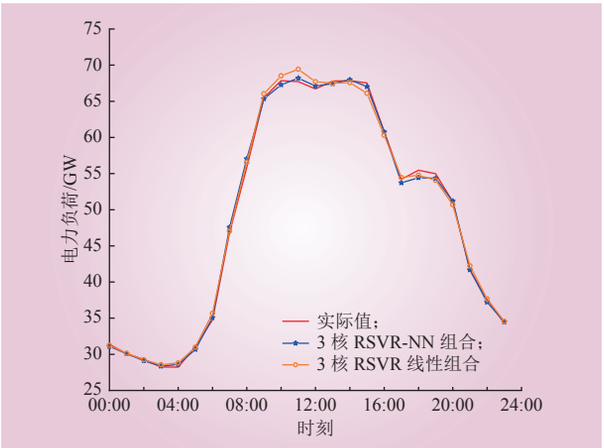


图 2　预测结果对比

Fig. 2　Comparison of forecasting results

4　结语

本文针对特征选择和多核 SVR 线性组合问题提出了解决优化方案，不仅使模型特征选择的方法更严谨，能够得到高相关低冗余的特征向量，同时保证较低的模型复杂度，还使用可以进行自学习的浅层神经网络作为单核 RSVR 模型的组合工具，从而替代了采用误差倒数法的线性组合方式。整个模型并非各类算法的盲目堆砌。通过实验对比，3 核 RSVR-NN 组合模型预测性能不仅优于单核模型与其他机器算法模型，也优于 3 核 RSVR 线性组合模型。

在后续的研究工作中，可尝试多个“混合核函数”SVR 模型组合或者将 SVR 与其他机器学习算法进行组合，进一步提升整体负荷预测效果。

参考文献：

[1] BARMAN M, DEV CHOUDHURY N B, SUTRADHAR S. A regional hybrid GOA-SVM model based on similar day approach for short-term load forecasting in Assam, India[J]. Energy, 2018, 145: 710–720.

[2] 苏振宇, 龙勇, 赵丽艳. 基于 regARIMA 模型的月度负荷预测效果研究 [J]. 中国电力, 2018, 51(5): 166–171.
SU Zhenyu, LONG Yong, ZHAO Liyan. Study on the monthly power load forecasting performance based on regARIMA model[J]. Electric Power, 2018, 51(5): 166–171.

[3] 张林, 罗晓初, 徐瑞林, 等. 基于时间序列的电力负荷预测新算法研

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net



究 [J]. 电网技术, 2006, 30(增刊2): 595–599.
ZHANG Lin, LUO Xiaochu, XU Ruilin, *et al*. Study on novel algorithm based on time series in power system load forecasting[J]. Power System Technology, 2006, 30(S2): 595–599.

[4] 方仍存, 周建中, 彭兵, 等. 电力负荷混沌动力特性及其短期预测 [J]. 电网技术, 2008, 32(4): 61–66.
FANG Rengcun, ZHOU Jianzhong, PENG Bing, *et al*. Chaotic dynamics of power load and its short-term forecasting[J]. Power System Technology, 2008, 32(4): 61–66.

[5] 于军琪, 聂己开, 赵安军, 等. 基于特征挖掘的 ARIMA-GRU 短期电力负荷预测 [J]. 电力系统及其自动化学报, 2022, 34(3): 91–99.
YU Junqi, NIE Jikai, ZHAO Anjun, *et al*. ARIMA-GRU short-term power load forecasting based on feature mining[J]. Proceedings of the CSU-EPSA, 2022, 34(3): 91–99.

[6] AHMAD A, JAVAID N, MATEEN A, *et al*. Short-term load forecasting in smart grids: an intelligent modular approach[J]. Energies, 2019, 12(1): 164.

[7] 祝学昌. 基于 IFOA-GRNN 的短期电力负荷预测方法研究 [J]. 电力系统保护与控制, 2020, 48(9): 121–127.
ZHU Xuechang. Research on short-term power load forecasting method based on IFOA-GRNN[J]. Power System Protection and Control, 2020, 48(9): 121–127.

[8] 张淑清, 段晓宁, 张立国, 等. Tsne 降维可视化分析及飞蛾火焰优化 ELM 算法在电力负荷预测中应用 [J]. 中国电机工程学报, 2021, 41(9): 3120–3130.
ZHANG Shuqing, DUAN Xiaoning, ZHANG Liguo, *et al*. Tsne dimension reduction visualization analysis and moth flame optimized ELM algorithm applied in power load forecasting[J]. Proceedings of the CSEE, 2021, 41(9): 3120–3130.

[9] 吕海灿, 王伟峰, 赵兵, 等. 基于 Wide&Deep-LSTM 模型的短期台区负荷预测 [J]. 电网技术, 2020, 44(2): 428–436.
LÜ Haican, WANG Weifeng, ZHAO Bing, *et al*. Short-term substation load forecast based on Wide & Deep-LSTM model[J]. Power System Technology, 2020, 44(2): 428–436.

[10] 朱凌建, 荀子涵, 王裕鑫, 等. 基于 CNN-Bi LSTM 的短期电力负荷预测 [J]. 电网技术, 2021, 45(11): 4532–4539.
ZHU Lingjian, XUN Zihan, WANG Yuxin, *et al*. Short-term power load forecasting based on CNN-BiLSTM[J]. Power System Technology, 2021, 45(11): 4532–4539.

[11] 魏震波, 余雷. 基于 FFT, DC-HC 及 LSTM 的短期负荷预测方法 [J]. 智慧电力, 2022, 50(3): 37–43.
WEI Zhenbo, YU Lei. Short-term load forecasting method based on FFT, DC-HC and LSTM[J]. Smart Power, 2022, 50(3): 37–43.

[12] 王新刚, 朱彬若, 顾臻. 基于综合能源计量大数据的中长期用电量预测 [J]. 中国电力, 2021, 54(10): 211–216.
WANG Xingang, ZHU Binruo, GU Zhen. Mid-and-long term load forecasting based on integrated power consumption data[J]. Electric Power, 2021, 54(10): 211–216.

[13] 侯慧, 王晴, 赵波, 等. 关键信息缺失下基于相空间重构及机器学习的电力负荷预测 [J]. 电力系统保护与控制, 2022, 50(4): 75–82.
HOU Hui, WANG Qing, ZHAO Bo, *et al*. Power load forecasting without key information based on phase space reconstruction and machine learning[J]. Power System Protection and Control, 2022, 50(4): 75–82.

[14] 李伟, 闫宁, 张振刚. 基于粗糙集的混合支持向量机长期电力负荷预测研究 [J]. 电力系统保护与控制, 2010, 38(13): 31–34.
LI Wei, YAN Ning, ZHANG Zhengang. Study on long-term load forecasting of MIX-SVM based on rough set theory[J]. Power System Protection and Control, 2010, 38(13): 31–34.

[15] 欧阳俊, 陆锋, 刘兴权, 等. 基于多核混合支持向量机的城市短时交通预测 [J]. 中国图象图形学报, 2010, 15(11): 1688–1695.
OUYANG Jun, LU Feng, LIU Xingquan, *et al*. Short-term urban traffic forecasting based on multi-kernel SVM model[J]. Journal of Image and Graphics, 2010, 15(11): 1688–1695.

[16] CHE J X, WANG J Z. Short-term load forecasting using a kernel-based support vector regression combination model[J]. Applied Energy, 2014, 132: 602–609.

[17] ZARE-NOGHABI A, SHABANZADEH M, SANGRODY H. Medium-term load forecasting using support vector regression, feature selection, and symbiotic organism search optimization[C]// 2019 IEEE Power & Energy Society General Meeting. Atlanta, GA, USA. IEEE, 2019: 1-5.

[18] 宋国锋. 一种基于 AICc 的新信息准则-bAICc[D]. 长春: 吉林大学, 2017.
SONG Guofeng. A new AICc-based information criterion-bAICc[D]. Changchun: Jilin University, 2017.

[19] WOLPERT D H, MACREADY W G. No free lunch theorems for optimization[J]. IEEE Transactions on Evolutionary Computation, 1997, 1(1): 67–82.

[20] CORTES C, VAPNIK V. Support-vector networks[J]. Machine Learning, 1995, 20(3): 273–297.

[21] 金樑. SVM 与神经网络的组合模型在短期电力负荷预测中的应用研究 [D]. 长春: 吉林大学, 2018.
JIN Liang. Research on short-term power load forecasting based on

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net



combination model of SVM and neural network[D]. Changchun: Jilin University, 2018.

[22] MARQUARDT D W. An algorithm for least-squares estimation of nonlinear parameters[J]. Journal of the Society for Industrial and Applied Mathematics, 1963, 11(2): 431–441.

[23] 孔祥玉, 郑锋, 鄂志君, 等. 基于深度信念网络的短期负荷预测方法 [J]. 电力系统自动化, 2018, 42(5): 133–139.
KONG Xiangyu, ZHENG Feng, E Zhijun, *et al*. Short-term load forecasting based on deep belief network[J]. Automation of Electric Power Systems, 2018, 42(5): 133–139.

[24] 陈如意, 江军, 陈珉, 等. 基于最大信息系数的变压器过热故障特征选择 [J]. 电力工程技术, 2020, 39(2): 140–145.
CHEN Ruyi, JIANG Jun, CHEN Min, *et al*. Feature selection of dissolved gases in power transformer based on maximal information coefficient[J]. Electric Power Engineering Technology, 2020, 39(2): 140–145.

[25] 谢家安. 基于体感温度的电力系统负荷分类及负荷预测 [J]. 电网与清洁能源, 2012, 28(8): 24–28.
XIE Jiaan. Load classification and load forecasting of power system based on apparent temperature[J]. Power System and Clean Energy, 2012, 28(8): 24–28.

作者简介：

徐宇颂（1996—），男，硕士，从事短期电力负荷预测研究，E-mail：2459894852@qq.com；

邹山花（1972—），女，副教授，从事物联网应用技术研究，E-mail：123066625@qq.com；

卢先领（1972—），男，通信作者，教授，从事无线传感器网络、大数据和数字医疗研究，E-mail：jnluxl@jiangnan.edu.cn。

（责任编辑　杨彪）

Short-Term Load Forecasting Based on Feature Selection and Combination Model

XU Yusong[1,2], ZOU Shanhua[3], LU Xianling[1,2]

(1. Key Laboratory of Advanced Process Control for Light Industry of Ministry of Education, Jiangnan University, Wuxi 214122, China;
2. School of Internet of Things Engineering, Jiangnan University, Wuxi 214122, China;
3. Jiangsu Key Construction Laboratory of IoT Application Technology, Wuxi 214100, China)

Abstract: A short-term load forecasting method based on feature selection and combination model is proposed. At first, the method divides the feature vectors into two sets according to the individual characteristics. Spearman rank-order correlation coefficient and max-relevance & min-redundancy algorithm are individually employed for selection. Bayesian information criterion is used to get the dimension of the optimal feature vector. And then, three different simple-kernel based support vector regression models are built using three kernel functions respectively and complete prediction. Finally, a neural network is set up for experimental analysis. The simulation results show that the proposed combination model has a great high forecasting accuracy and robustness.

This work is supported by National Natural Science Foundation of China (No.61573167), Foundation for “Integration of Cloud Computing and Big Data” of Innovation of Science and Education (No.2017 A13055).

Keywords: short-term load forecasting; support vector regression; shallow neural network; combination model

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net